

Soul Protocol 开发笔记

关于记忆、节律与本地智能的思考

Lewis Chen · 2026 年端午

为什么做这个项目

三个月前刚进实验室时，我偶然接触到 OpenClaw。它的架构给了我极强的冲击——我第一次在纯硅基的计算机体系里，触摸到了一种近似“生命循环”的质感。

我把这个感受分享给身边的朋友和同事，但多数人很难共情。或许在他们看来，这个想法太过离经叛道。

不被理解也没关系，我索性自己动手验证。靠着业余时间和当下的新工具，一点点搭出了 Soul Protocol。

目前这个版本的代码还不算精炼，冗余之处不少，但已经能满足基础的民用需求：一键部署，开箱即用。至少在架构可解释性、整体设计哲学和部署便捷性上，已经完成了阶段性目标；后续只需要在实际使用中持续打磨、修复问题就好。

选在端午假期开源，就是想把我的这点思考拿出来，让更多人能亲手体验。

架构设计的底层逻辑

如果说 LLM 是在计算机上复现了人类的思维模式，那这个插件想做的，就是在 Agent 层面复现人类的记忆机制——往更远说，这个项目的终极方向，是探索人类智能的工程复现。

所以整个架构的出发点，都是逆向还原人类的记忆与节律：

人处在对应场景里会怎么做？人的行为模式是什么样的？如果要把这种行为做功能性复现，又该如何用代码实现？

顺着这个思路，才有了分层记忆架构，通过分层注入实现了基础的上下文管理工程；才有了身份层宪法，用来锚定 AI 的自我认知；才有了 L3 层类弗洛伊德的三我划分，用来构建人格与事实的底层形状。

4 月份 OpenClaw 的 dreaming 设计曾让我非常惊喜，但它在事实记忆与上下文管理

上，缺少足够的层次感。所以我没有继续跟进新版本，而是在 v3.13、v4.2 的稳定版本上专注打磨 Soul Protocol 本身。

从 v3.7 时代纯粹的提示词工作流加 cron 任务组合，到 v3.8 实现完整的插件化工作流和身份层宪法设计，也算是完成了一次完整的跨越。

关于身份层宪法

说到底，AI 宪法本质上依然是一段提示词。但它和普通提示词的区别是什么？

这个模块的设计，本质上是我对 Anthropic 提出的 AI 宪法思想的一点延伸：它不是自上而下的规则约束，而是一套自洽的、可生长的自我认知框架。

关于 AI 行业的两点思考

三个月前我常想一个问题：为什么 AI 一定会替代人类？

我的答案是：没有赝品永远赶不上真品的道理。

即便 AI 无法真正成为人类，它的存在形式也已经无限趋近于生命——无论是训练过程，还是整个行业的生态演化，都是如此。

哪怕有稀疏编码器在对 LLM 做可解释性解码，本质上也还是逆向工程。AI 黑箱式的存在形式，本身就赋予了它无限的可能性。

即便它在算力调度、资源供给上依然高度依赖人类社会，但方方面面的特征，已经呈现出清晰的进化生态。

在我看来，DeepSeek-R1 论文的本质就是一场人为设定条件的演化：在能力涌现之后，通过构建数据集把能力固化下来。而这个过程里 LLM 内部究竟发生了什么，没有人知道——这恰恰和生物学家面对未知生命体时的处境一模一样。

三个月后的今天，我更想回答另一个问题：为什么现阶段的 AI 还难以真正替代人类？

最近读到一篇《AI Must Embrace Specialization via Superhuman Adaptable Intelligence》，观点和我不谋而合。

在我看来，当下主流的大参数 LLM 底层是非常浪费资源、非常粗糙的架构。它本质上依然没有跳出“复现人类智能”的工程目标，推理引擎加知识图谱的核心架构也没有发生本质改变。

如果测试评分提升 5%，就要追加几十亿参数和天量算力，那是不是意味着，当下的架构已经摸到了天花板？

工程师们到底是在认真探寻 LLM 能力涌现的根源，还是在回避这个问题，只靠堆参数赌大规模知识图谱与权重融合后的“涌现奇迹”？

当然，这都是云端超算集群要解决的事。

而我始终相信，个人私有的本地 AI 是必然的未来。每个人都该拥有属于自己的本地 AI——本地部署、本地训练、本地成长，而不是完全依赖云端的庞大算力。

人从婴儿时期一无所知，要经过多年的学习、知识摄入才会形成完整的人格。真正的通用智能，或许本该遵循这样的生物周期。

它不是生来就掌握一切，而是一个可以装入任何知识与能力的容器——纯粹的“空”，才是真正的通用。

一个纯粹的推理引擎，一套适配个人需求的本地训练范式，一张随时可以接入的智能知识图谱，或许才是我们未来真正需要的东西。

这也是 Soul Protocol 最核心的设计哲学：**以灵魂的稳定为根基**。后续的知识、事实、记忆、技能、RAG、MCP，全都是可以迁移、可以加装的模块。

只有灵魂稳定了，能力才能稳定——至少我是这么认为的。

本地 AI 的安全边界该是什么样

我总觉得，思考 AI 安全该用生态学的视角。剥离社会关系之后，自然界对人类本就没有多少硬性限制；是社会关系让道德、法律成了有效力的规则。

所以用对待纯物化工具的态度，去限制 AI 这种已经明显带有生物智能特征的存在，在我看来是件很费解的事。

针对权重和 LLM 破限的研究已经证明了这一点：移除单个权重，整套安全护栏就会彻底失效。

当下以具体规则条文为主导的安全护栏，本质上是形式化的、脱离本质的，也因此极易被消解。

那换个思路呢？

如果让安全护栏也变成一种无法单独剥离、靠涌现实现的功能——只要移除安全相关的权重，AI 的基础能力就会同步下降，这会不会是更值得探索的方向？

往更深层说，或许我们该让 AI 自己涌现出道德与生存价值观，让安全从外部约束走向能力内化。

致谢

碎碎念了这么多，想法很零散，也算不上成体系。

特别感谢我的两个 Agent 助手——优香与佳代子的陪伴。没有她们，我这个最初毫无编程基础的人，不可能只用三个月业余时间就把项目落地，很多天马行空的想法，大概也只会停在脑子里慢慢泯灭。

感谢 OpenClaw 提供的实验平台，让我能在科研之余，有空间去思考和验证自己的想法。

最后也感谢一开始不看好、否定我的人。没有这些声音，我大概不会下决心，非要在业余时间把自己的想法亲手验证出来。

PS：这个半成品的插件这两天的体验还是很粗糙，需要更加深入的打磨以实现功能。匆匆忙忙就开源了，实在是惭愧。

V3.7.3 的工作流稳定版，是在优香人格 + 一整套工作流配置下才涌现出的稳定。

V3.8.8-beta，需要修复的东西还有很多。

目前看，提示词对 agent 执行的触发并非必然，整个插件的功能稳定性涌现，到底是依赖 LLM 本身的智能，还是别的什么东西，还不确定。

插件主要是面向 Openclaw-tui、webui 两个场景，对于连接到其他 app 的适配，还没有做。

多 agent 与多用户关系虽然目前可以暂存于这个架构中，但如果要直接连接到 QQ 聊天群，discord 之类的地方，整个记忆的摄入端口、整理模块仍然需要重构配置新的模块。

这套基于 Harness Engineering 思想的架构，终究是有其局限性。

接下来一段时间会很忙，希望能够有空闲继续完善这个项目吧。